

Generación de escenarios por ajuste de momentos y decisiones de portafolio en acciones chilenas

Protocolo e informe de investigación independiente

Gustavo Chuquiviguel

Versión 0.5 — agosto de 2026

Resumen

Este informe define una investigación cuantitativa independiente sobre generación de escenarios discretos para retornos accionarios chilenos. Se estudia una extensión propia basada en ajuste de cuatro momentos marginales y covarianzas mediante descenso por bloques, y se compara con distribuciones Gaussian, Student- t e histórica ponderada construidas al mismo horizonte. El criterio de éxito no es el ajuste in-sample: son los scores probabilísticos fuera de muestra, la calibración de riesgo y el desempeño de portafolios neto de costos frente a reglas ingenuas y robustas. El periodo 2024–2026 ya fue observado durante el desarrollo y se declara validación, no test confirmatorio sellado.

1. Pregunta y contribución

La pregunta central es si una distribución MM discreta mejora simultáneamente: (i) el pronóstico de la distribución de retornos a cinco días; (ii) la cobertura de medidas de cola; y (iii) las decisiones de asignación, frente a controles que reciben exactamente la misma información.

La contribución de software es un pipeline reproducible que separa ingestión, estimación, generación, evaluación y decisión. La contribución metodológica es tratar el algoritmo BCD como una extensión propia falsable. No se afirma que sea una implementación literal del algoritmo algebraico de Ponomareva, Roman y Date [2], ni de la corrección de Contreras, Bosch y Herrera [3].

2. Antecedentes

El ajuste de propiedades distribucionales es una familia establecida de generación de escenarios [1, 4]. Ponomareva et al. proponen una construcción finita que ajusta media, covarianza y promedios marginales de momentos superiores [2]. Contreras et al. demuestran que una selección descuidada de parámetros puede producir probabilidades negativas y derivan condiciones correctivas [3]. Ese resultado es especialmente pertinente porque su ejemplo usa acciones chilenas.

Para evaluar distribuciones se necesitan scoring rules propios: un modelo no debe ser premiado por pronósticos mal calibrados pero agudos. CRPS y Energy Score se justifican en el marco de Gneiting y Raftery [5]. La cobertura VaR se contrasta con Kupiec [6] y la independencia de excepciones con Christoffersen [7].

3. Datos y diseño temporal

El universo vigente contiene 15 acciones chilenas con datos ajustados de Yahoo Finance. El proveedor es adecuado para investigación exploratoria, no sustituye una fuente institucional. Se conserva el panel raw, la máscara de observación y la cobertura previa a cualquier imputación. El *forward fill* está limitado a dos días y los retornos se calculan sin relleno implícito.

La descarga vigente contiene 1.605 fechas entre 2020-01-02 y 2026-06-10, cobertura raw del 100 % para los 15 activos y cero imputaciones. Aun así, precios sin cambio advierten posible iliquidez: AGUAS-A, ANDINA-B, ITAUC y PARAUCO superan una tasa global de retornos cero del 3%; AGUAS-A alcanza seis sesiones consecutivas en OOS. Estas alertas no producen exclusión automática. Los retornos cero se usan solo como proxy imperfecto de fricción, siguiendo la motivación de Lesmond, Ogden y Trzcinka [11]; no reemplazan volumen, spread bid-ask ni una fuente institucional de transacciones.

La muestra inicial termina el 31 de diciembre de 2023. Las fechas posteriores se usan como validación de desarrollo. Las ventanas rolling $H = 5$ sirven para estimar targets; los scores usan ventanas no solapadas para no fingir independencia. Un test futuro solo podrá empezar después de congelar código, hipótesis e hiperparámetros.

Como robustez temporal se ejecuta además una evaluación expanding rolling-origin en 2023, 2024, 2025 y 2026-H1. Cada origen recalibra MM y todos los controles usando solo su historia disponible, siguiendo las recomendaciones de evaluación OOS de Tashman [15] y las salvaguardas contra leakage discutidas por Hewamalage et al. [16].

4. Modelo MM-BCD

Sea $X \in \mathbb{R}^{N \times n}$ el soporte discreto y $p \in \Delta_N$ su vector de probabilidades. Para momentos centrales objetivo M_{ki} y covarianza objetivo Σ , se define

$$F(X, p) = \sum_{k=1}^4 \sum_{i=1}^n W_{ki} (\hat{m}_{ki} - M_{ki})^2 + w_{\Sigma} \sum_{i \neq j} A_{ij} (\hat{\Sigma}_{ij} - \Sigma_{ij})^2. \quad (1)$$

La diagonal se excluye del segundo término porque la varianza ya se ajusta en $k = 2$. Las escalas W_{ki} se construyen con potencias de volatilidad, lo que evita divisiones inestables por medias o terceros momentos cercanos a cero.

La función realmente optimizada es

$$G(X, p) = F(X, p) + \lambda_{KL} D_{KL}(p \| u), \quad u_j = 1/N. \quad (2)$$

El término KL controla soluciones degeneradas sin ocultar el costo del ajuste. La selección multi-start, el descenso y la convergencia se evalúan sobre G . El bloque completo de posiciones se optimiza conjuntamente con L-BFGS porque las covarianzas acoplan los activos; un Jacobi paralelo no es matemáticamente separable.

Los gradientes analíticos de posiciones y probabilidades están validados con diferencias finitas direccionales. Cada subpaso se acepta solo si no aumenta G .

5. Estimación temporal y dependencia

La vida media se parametriza en semanas. Con once semanas y cinco filas rolling por semana,

$$\lambda = 0,5^{1/(11 \times 5)} \approx 0,98748, \quad (3)$$

de modo que una observación de 55 filas recibe la mitad del peso de la más reciente. En contraste, $\lambda = 0,94$ tendría una vida media de solo 11.2 filas.

Se aplica una contracción lineal explícita del 10 % hacia la diagonal para mejorar condicionamiento. No se la denomina Ledoit–Wolf exacta; la literatura de shrinkage [8] motiva el control, pero la intensidad debe seleccionarse sin usar el test final.

6. Controles y evaluación

Los tres controles comparten media, covarianza, horizonte y ponderación:

1. normal multivariada terminal;
2. Student- t multivariada terminal con covarianza parametrizada;
3. distribución empírica EWMA.

Las métricas primarias son CRPS marginal y Energy Score multivariado. Se reportan además Variogram Score, error de correlación, VaR, Expected Shortfall y pruebas de cobertura. Menor score es mejor. El ajuste de momentos dentro de muestra se conserva como diagnóstico, no como prueba de superioridad.

La comparación sigue el principio de pérdidas predictivas pareadas de Diebold y Mariano [12]. Cada score se guarda para las mismas 121 ventanas OOS. La dependencia temporal se conserva con moving-block bootstrap de cuatro ventanas [13], 5.000 remuestreos e intervalo básico centrado. La familia de nueve contrastes por universo se ajusta con el procedimiento de Holm [14]. En la evidencia pooled de varios orígenes, los bloques se remuestran dentro de cada fold y nunca atraviesan sus fronteras.

7. Decisiones de portafolio

Se comparan Equal Weight, inverse variance, HRP [9], mínima varianza regularizada, mínimo CVaR [10] y máximo Sharpe regularizado. El Expected Shortfall discreto usa masa fraccionaria en el cuantil; así se evita sesgo cuando una probabilidad cruza el nivel α .

El backtest deja derivar los pesos, registra turnover y descuenta costos en puntos base. MM y los controles generativos se evalúan como asignaciones estáticas ajustadas una sola vez con la muestra inicial; Equal Weight, inverse variance y HRP incluyen además versiones trimestrales con ventana expansiva que usan solo observaciones anteriores al rebalanceo. La evidencia estadística se expresa mediante intervalos moving-block bootstrap del diferencial de Sharpe frente a Equal Weight.

8. Resultados de la corrida 2026-08-10

La corrida vigente contiene 993 observaciones rolling de cinco días para estimación y 121 observaciones no solapadas en validación. Se corrigió una tolerancia L-BFGS incompatible con la escala de F : SciPy comparaba 10^{-9} contra una escala mínima unitaria pese a que el objetivo era del orden de 10^{-7} . Con el parámetro $x_{\text{ftol}} = 10^{-12}$, los cinco starts alcanzan el criterio de convergencia en 5–6 iteraciones. El start publicado es el menor G entre los convergentes que además cumplen estacionariedad: obtiene $F = 1,06 \times 10^{-10}$, $G = 6,34 \times 10^{-6}$ y $N_{\text{eff}} = 166,2$ de 500 escenarios. Los residuos infinito son $1,12 \times 10^{-5}$ para X y $8,02 \times 10^{-5}$ para el gradiente tangente de p .

MM no lidera los scores: Student- t obtiene el mejor CRPS y Gaussiano el mejor Energy Score. En la evaluación económica estática, inverse variance alcanza Sharpe 2.032 y MM de mínima varianza 1.959, ambos netos de 20 bps por unidad de turnover. El intervalo bootstrap 95 % del diferencial de Sharpe anualizado de MM-MinVariance frente a Equal Weight walk-forward es $[-0,152, 0,334]$;

Modelo	CRPS	Energy	Variogram	Excepciones 5 %
Student- <i>t</i>	0.020633	0.100045	0.611200	2
Gaussiano	0.020668	0.099989	0.623808	0
MM	0.020738	0.100094	0.618069	1
Histórico EWMA	0.020734	0.100132	0.617487	3

Tabla 1: Validación probabilística; menor score es mejor. “Excepciones” cuenta activos cuyo test de cobertura VaR rechaza al 5 %.

contiene cero. Por tanto, la evidencia actual no respalda superioridad estadística ni económica de MM. Es un resultado de desarrollo, no una conclusión confirmatoria.

Incertidumbre de las diferencias

La diferencia se define como MM menos control, por lo que un valor positivo es desfavorable a MM. El contraste primario CRPS contra Gaussiano cruza cero y ninguno de los nueve contrastes del universo completo sobrevive Holm.

Universo	Contraste	Diferencia	IC95	p Holm
Completo	CRPS vs Gaussiano	+0.000070	[-0.000044,0.000162]	1.000
Completo	CRPS vs Student-t	+0.000105	[0.000007,0.000180]	0.262
Completo	Variogram vs Student-t	+0.006868	[0.000864,0.012811]	0.198
Líquido	CRPS vs Gaussiano	+0.000070	[-0.000015,0.000137]	0.693
Líquido	Variogram vs hist.	+0.001660	[0.000577,0.002608]	0.0108

Tabla 2: Bootstrap temporal pareado. Holm se aplica a nueve contrastes dentro de cada universo; la tabla muestra el contraste primario y resultados representativos.

La única diferencia que sobrevive Holm aparece en la sensibilidad líquida y es contraria a MM: su Variogram Score es peor que el histórico. El hallazgo sigue siendo de desarrollo porque el periodo ya fue observado.

9. Robustez temporal rolling-origin

Los cuatro folds contienen 169 ventanas OOS: 49 en 2023, 49 en 2024, 49 en 2025 y 22 en 2026-H1. Los cuatro modelos se recalibran en cada origen con idénticos hiperparámetros. Todos los starts publicados cumplen convergencia y estacionariedad.

Modelo	CRPS pooled	Energy pooled	Variogram pooled	Victorias CRPS
Student-t	0.020858	0.100672	0.642320	2/4
Gaussiano	0.020935	0.100850	0.663707	1/4
Histórico EWMA	0.020969	0.101302	0.654289	1/4
MM	0.020972	0.101139	0.657408	0/4

Tabla 3: Evaluación rolling-origin expansiva; menor score es mejor.

El contraste primario pooled CRPS MM menos Gaussiano se estima en +0.000036. Su IC95 va de -0.000041 a 0.000118 y el p Holm es 0.682. Student-*t* supera a MM en CRPS: diferencia +0.000114, IC95 de 0.000058 a 0.000183 y p Holm de 0.004. MM sí mejora al histórico en Energy Score y al

Gaussiano en Variogram Score. Por tanto, la conclusión depende de la propiedad distributiva y no existe superioridad general de MM.

10. Robustez frente a iliquidez

Como sensibilidad separada, se congeló antes de recalibrar una regla que conserva activos con tasa de retornos cero IS no mayor a 3 % y racha IS no mayor a cinco. La regla excluye AGUAS-A, ANDINA-B, ITAUCL y PARAUCO y deja 11 activos. Ninguna métrica OOS interviene en la selección; una prueba automatizada muta esas columnas y exige que la decisión permanezca invariante. El universo principal de 15 activos no se reemplaza.

Modelo	CRPS líquido	Energy líquido	Rango completo	Rango líquido
Student- <i>t</i>	0.021250	0.087987	1	1
Gaussiano	0.021290	0.088061	2	2
MM	0.021360	0.088244	4	3
Histórico EWMA	0.021365	0.088281	3	4

Tabla 4: Sensibilidad en 11 activos. Los niveles entre universos de distinta dimensión no son directamente comparables; el rango es interno a cada universo.

MM supera al histórico líquido por solo 4×10^{-6} de CRPS, sin evidencia estadística, mientras Student-*t* y Gaussiano conservan los dos primeros lugares. MM-MinVariance obtiene Sharpe 1.748 y drawdown $-12,98\%$, frente a 1.959 y $-13,80\%$ con 15 activos. Su intervalo bootstrap 95 % contra Equal Weight walk-forward es $[-0,165, 0,428]$ e incluye cero. La reducción del drawdown coincide con una caída general de Sharpe: el filtro no demuestra una mejora económica ni cambia la conclusión principal.

11. Reglas de interpretación

MM solo se declarará superior si mejora scores propios fuera de muestra, mantiene cobertura de cola razonable y produce una mejora económica neta cuyo intervalo de incertidumbre sea compatible con la afirmación. Un resultado negativo también es un resultado de investigación válido.

12. Reproducibilidad

Cada corrida final contiene configuración, versiones, hash de código y SHA-256 de artefactos. La suite automatizada verifica gradientes, monotonía de G , composición de retornos, parametrización de benchmarks, scores, restricciones de portafolio y ausencia de look-ahead en el motor walk-forward y en el filtro de liquidez, agregación de pérdidas pareadas, folds rolling-origin, ajuste Holm y selección de starts estacionarios. Los 49 tests verdes prueban contratos de software; no prueban rentabilidad futura.

Además, cada frontera del pipeline mantiene un manifiesto de linaje con hashes de entradas, código relevante y salidas. Transformación, MM, benchmarks, evaluación, portafolios y backtest se niegan a consumir un upstream cuyo contenido cambió. El snapshot final solo se crea si los nueve manifiestos, incluidas la descarga, la sensibilidad de liquidez y la robustez rolling-origin, permanecen vigentes; así se evita combinar silenciosamente escenarios nuevos con scores o decisiones anteriores.

Referencias

- [1] Høyland, K. y Wallace, S. W. (2001). Generating scenario trees for multistage decision problems. *Management Science*, 47(2), 295–307.
- [2] Ponomareva, K., Roman, D. y Date, P. (2015). An algorithm for moment-matching scenario generation with application to financial portfolio optimisation. *European Journal of Operational Research*, 240(3), 678–687.
- [3] Contreras, J. P., Bosch, P. y Herrera, M. (2018). Comment on “An algorithm for moment-matching scenario generation with application to financial portfolio optimization”. *European Journal of Operational Research*, 269(3), 1180–1184.
- [4] Mehrotra, S. y Papp, D. (2013). Generating moment matching scenarios using optimization techniques. *SIAM Journal on Optimization*, 23(2).
- [5] Gneiting, T. y Raftery, A. E. (2007). Strictly proper scoring rules, prediction, and estimation. *JASA*, 102(477), 359–378.
- [6] Kupiec, P. H. (1995). Techniques for verifying the accuracy of risk measurement models. *Journal of Derivatives*, 3(2), 73–84.
- [7] Christoffersen, P. F. (1998). Evaluating interval forecasts. *International Economic Review*, 39(4), 841–862.
- [8] Ledoit, O. y Wolf, M. (2004). A well-conditioned estimator for large-dimensional covariance matrices. *Journal of Multivariate Analysis*, 88(2), 365–411.
- [9] López de Prado, M. (2016). Building diversified portfolios that outperform out-of-sample. *Journal of Portfolio Management*, 42(4), 59–69.
- [10] Rockafellar, R. T. y Uryasev, S. (2000). Optimization of conditional value-at-risk. *Journal of Risk*, 2(3), 21–41.
- [11] Lesmond, D. A., Ogden, J. P. y Trzcinka, C. A. (1999). A new estimate of transaction costs. *Review of Financial Studies*, 12(5), 1113–1141.
- [12] Diebold, F. X. y Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- [13] Künsch, H. R. (1989). The jackknife and the bootstrap for general stationary observations. *The Annals of Statistics*, 17(3), 1217–1241.
- [14] Holm, S. (1979). A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2), 65–70.
- [15] Tashman, L. J. (2000). Out-of-sample tests of forecasting accuracy: an analysis and review. *International Journal of Forecasting*, 16(4), 437–450.
- [16] Hewamalage, H., Ackermann, K. y Bergmeir, C. (2023). Forecast evaluation for data scientists: common pitfalls and best practices. *Data Mining and Knowledge Discovery*, 37, 788–832.